



Micro proyecto 2

Rubén Manrique

Universidad de Los Andes, Colombia

1 Introducción

En este documento se describe de manera completa el micro proyecto 2 del curso, el cual comprende el contenido de la semana 3 y 4. Además de conocer el propósito del proyecto, también se presenta la rúbrica con la que se realizará la evaluación del mismo. El documento está estructurado de la siguiente forma:

Tabla de Contenido

1	Introducción	1
2	Resultados de Aprendizaje	1
3	Descripción del micro proyecto	2
3.1	Detalles del dataset	2
4	Rúbrica de la nota del micro proyecto	2
4.1	Implementación y entrenamiento de arquitectura GPT desde 0	2
4.2	Finetuning de GPT2	2
4.3	Resultados obtenidos	3
4.4	Cumplimiento de requisitos de la actividad	3
5	Entregables en Coursera	3

2 Resultados de Aprendizaje

Con esta actividad se busca que el estudiante pueda poner en práctica arquitecturas estado del arte para generación de texto. Tras realizar esta actividad se espera que el estudiante esté en capacidad de:

1. Estructurar un corpus de texto de forma que pueda ser usado para entrenar un modelo de lenguaje.
2. Utilizar la arquitectura de Transformers para implementar modelos de lenguaje desde cero.
3. Utilizar modelos pre-entrenados como punto de inicio para el entrenamiento de modelos especializados.
4. Hacer finetuning de un modelo pre-entrenado para mejorar el desempeño en una tarea específica.

3 Descripción del micro proyecto

El objetivo del micro proyecto es entrenar un modelo de lenguaje basado en Transformers capaz de generar texto en el estilo del famoso escritor William Shakespeare.

Usted debe comparar los resultados obtenidos por medio de dos modelos distintos. El primero de ellos, debe ser un modelo de Pytorch entrenado desde cero (puede hacer la implementación desde cero o utilizar como base la clase *Transformer* de la librería), el segundo modelo debe ser el resultado del finetuning del modelo *GPT2* de *OpenAI*. Para que el desempeño de los modelos sea comparable medido a través de la función de pérdida, el tamaño del vocabulario debe ser el mismo (50.257).

Compare el mínimo valor de pérdida obtenido en el set de validación para los dos modelos, y realice por lo menos 3 ejemplos de generación de texto.

3.1 Detalles del dataset

El dataset se compone de una serie de obras de William Shakespeare concatenadas en un mismo archivo de texto. El dataset original puede descargarse aquí.

A partir de este corpus de texto, usted debe definir los subsets que usará como entrenamiento y validación durante el entrenamiento de sus modelos. Se deben poder generar las particiones del corpus dentro del código del notebook que va a entregar.

4 Rúbrica de la nota del micro proyecto

La nota del micro proyecto se compone de la forma descrita en la siguiente tabla:

Item	Porcentaje de la nota
Implementación y entrenamiento de arquitectura GPT desde 0	10%
Finetuning de GPT2	50%
Resultados obtenidos	40%

Table 1: Composición de la nota del micro proyecto

4.1 Implementación y entrenamiento de arquitectura GPT desde 0

El estudiante debe implementar una arquitectura GPT para el entrenamiento del modelo en el corpus de texto dado. Debe utilizar el mismo tamaño de vocabulario del modelo GPT2 (50.257). Se puede guiar del tutorial de la semana.

4.2 Finetuning de GPT2

El estudiante debe cargar el modelo GPT2 junto con sus pesos para luego realizar el finetuning del modelo en el corpus de obras de Shakespeare.

Se recomienda cargar el modelo más pequeño de GPT2 (124M de parámetros) en Pytorch, junto con el tokenizador utilizado por el modelo mediante la librería *transformers* de *Hugging Face*. Puede hacerlo de la siguiente manera:

```
from transformers import GPT2Tokenizer, GPT2LMHeadModel
tokenizer = GPT2Tokenizer.from_pretrained('gpt2')
model = GPT2LMHeadModel.from_pretrained('gpt2')
```

Para el finetuning del modelo GPT2, tenga en cuenta que al ser un modelo grande, debe ajustar su entrenamiento a las limitaciones de memoria de sus GPUs, por lo tanto utilice un tamaño de contexto, y tamaño del batch adecuados.

4.3 Resultados obtenidos

El estudiante debe reservar al menos una pequeña porción de los datos para evaluar la capacidad de generalización del modelo. Se evaluará el grado en el que los dos modelos demuestran tener la capacidad de ajustarse a los datos, y las acciones realizadas para evitar el sobre ajuste de los datos.

El estudiante debe hacer un análisis de la comparación del desempeño del modelo, la cual además de los resultados de la función de costo durante el entrenamiento, debe incluir 3 ejemplos de generación de texto para cada uno de los modelos (la función de generación de texto debe implementarse desde cero).

4.4 Cumplimiento de requisitos de la actividad

Recuerde que su entrega no tendrá validez si no cumple los requisitos que se mencionan a continuación. Por lo tanto, obtendrá una calificación de 0 en la actividad correspondiente al micro proyecto.

Los requisitos son los siguientes:

- Para el entrenamiento del modelo solo se debe usar los datos proporcionados, no podrá usar datos de otras fuentes a menos que se le haya indicado explícitamente.
- Debe implementar y entrenar los modelos haciendo uso de *Pytorch*, y de las librerías que se le haya indicado únicamente.
- El código enviado debe poder ser ejecutado por el equipo evaluador, y el código debe ser completamente de su autoría.
- Debe crear y entregar los checkpoints con las versiones finales de sus modelos guardados mediante `torch.save`.

5 Entregables en Coursera

En la semana 4 del curso se habilitará una actividad en donde usted debe subir los siguientes entregables:

1. Jupyter Notebook que se utilizó para realizar la implementación y el entrenamiento de los modelos, junto con los análisis de los resultados obtenidos.
2. Dos archivos con los checkpoints de las versiones finales de sus modelos.